SPRİNT RAPORU • MAKİNE ÖĞRENMESİ & DAVRANIŞSAL ANALİTİK

TrollLens: Marka İtibarına Yönelik Koordineli Sahte Saldırıların Tespiti

Metne değil, davranışsal ayak izine odaklanan dilden bağımsız anti-astroturfing mimarisi.

PAZARLAMA PROBLEMİ

Marka kimliği ve itibarını hedef alan yapay krizler.

TEMEL AMAÇ

Sosyal medyadaki koordineli bot ağlarını anında ayrıştırmak.

ÇÖZÜM HİPOTEZİ

Metin yerine etkileşim ve zaman örüntüsü analizi.

VERİ HAZIRLIĞI VE ÖN İŞLEME

Büyük Veri Yönetimi ve Tabakalı Örnekleme

Boyut Optimizasyonu

8 GB → 329 MB

Pandas chunksize ile bellek krizini önleme.

Örneklem Hacmi

1.14M Satır

22.8M tweet havuzundan tabakalı örnekleme.

Sınıf Dengesi

%47 / %53

Dengeli dağılım: 542K organik, 601K troll.

Dilden Bağımsız Temizlik: Metin sütunları (BoW) elendi, eksik sayısal değerler sıfırlandı ve modelin evrensel uygulanabilirliği korundu.

ÖZELLİK MÜHENDİSLİĞİ (FEATURE ENGİNEERİNG)

Davranışsal İmzaların Çıkarılması

Zaman Serisi İmzaları

hour & time_of_day: Planlı saldırı ve vardiya saatleri tespiti.

is_weekend: Hafta sonu hedef alma dinamikleri.

Etkileşim Anormallikleri

retweet_to_like_ratio: Beğeni basmadan yapılan koordineli retweet'ler.

total_engagement: Bot ağının yarattığı suni dalga boyu.

Yayılım Davranışı

tags_and_urls: Spam yayılımı ve gündem manipülasyonu.

user_mentions: Koordineli hedef gösterme sıklığı.

İçerik değişebilir; ancak eş zamanlı yayılım ve anormal retweet refleksleri gizlenemez.

MODEL EĞİTİMİ (MODEL EXPLORATİON)

LightGBM ile Yüksek Hızlı Baseline

Eğitim Süresi

5.87 sn

14 davranışsal değişken üzerinde yaklaşık 1 milyon örnek 6 saniyenin altında eğitildi.

Histogram Tabanlı Öğrenme

C++ çok çekirdek optimizasyonu ile minimum bellek tüketimi.

%80 Eğitim / %20 Test Bölünmesi

914.924 eğitim, 228.731 test örneğiyle tabakalı doğrulama.

GNN Öncesi Sağlam Temel

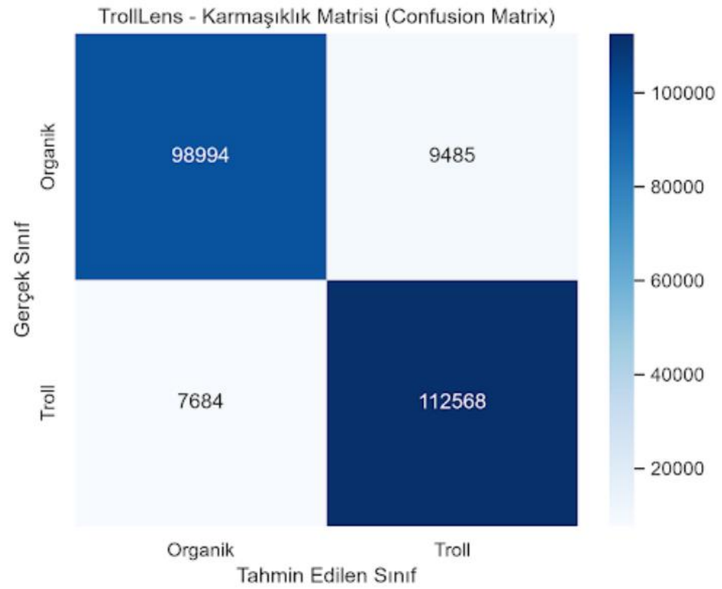
Sonraki aşamadaki ağ modelleri (Graph Neural Networks) için güçlü kıyaslama noktası.

MODEL BAŞARIMI VE METRİKLER

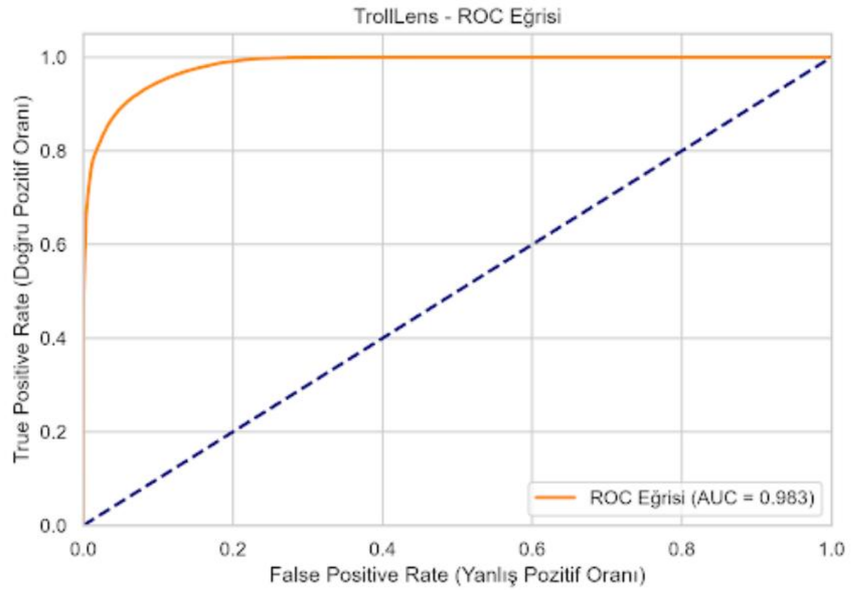
Test Sonuçları: 228.731 Tweet Üzerinde Doğrulama

Doğruluk (Accuracy)	F1-Score	ROC-AUC Skoru	Troll Yakalama (Recall)
%92.49	%92.91	%98.34	%94.00

Karmaşıklık Matrisi (Confusion Matrix)

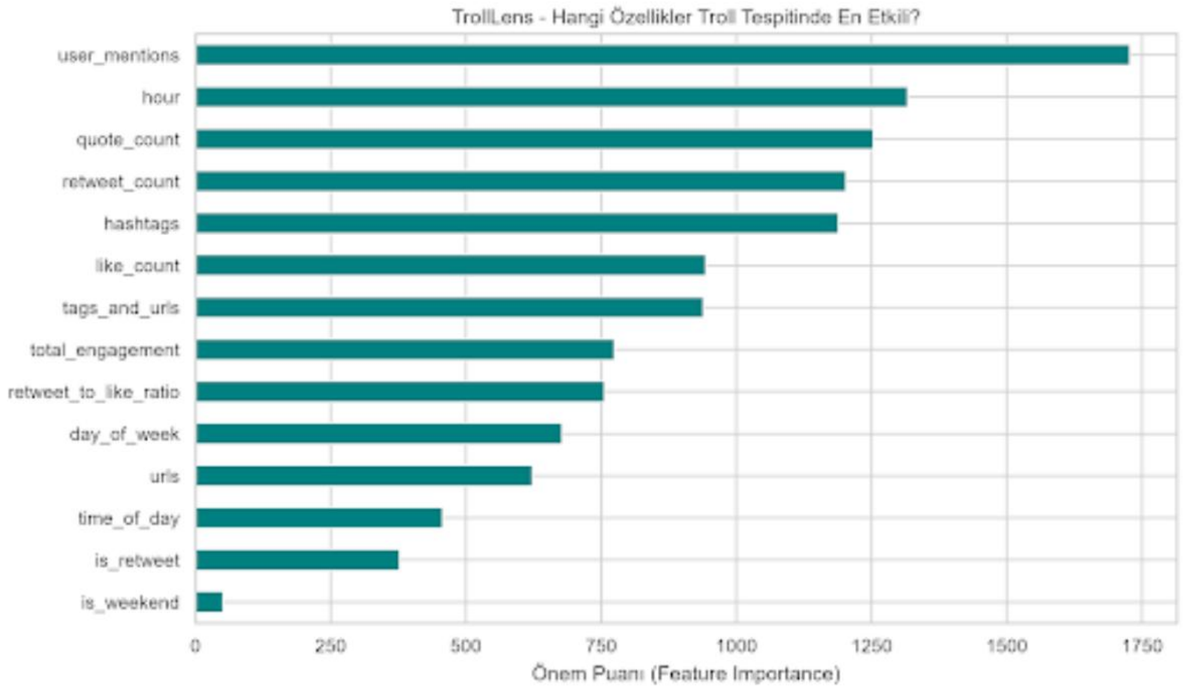


ROC Eğrisi (AUC = 0.983)



ÖZELLİK ÖNEMİ VE GELECEK ADIMLAR

Trolleri En Çok Ne Ele Veriyor?



1. En Kritik Davranışsal İpuçları

user_mentions & hour: Koordineli hedef gösterme ve belirli mesai saatleri en belirleyici faktörler.

2. Marka ve PR Değeri

Kriz anında bütçe israfını önleme; gerçek müşteri şikayetleri ile yapay bot saldırılarını saniyeler içinde ayırma.

3. Gelecek Adım: GNN Mimarisi

`all_users_hashed.csv` verisiyle retweet ağını Graph Neural Networks ile modelleyip doğruluğu **%95+** seviyesine taşımak.